Arquitectura del Proceso ETL

Proyecto: Sistema de Gestión y Migración Académica (SGMA)

Versión: 1.1 (revisión de la v1.0)

Fecha: Noviembre de 2026

Estado: Borrador, Fase 2 (tarjeta "Diseñar la arquitectura del proceso ETL y el diagrama de flujo de datos")

Base: SRS v1.2 (RF-MIG-01 a 06, RF-VAL-01 y 02, RNF-02, RNF-07), Diccionario v1.2 (secciones 2, 4 y 5) y esquema `gestion_academica.sql`

Diagrama: `Diagrama_Flujo_ETL_v1.1.drawio`

1. Resumen

El ETL es el módulo de migración inicial: se ejecuta una sola vez en producción para incorporar las planillas legadas a la base de datos. La v1.0 lo describía como el núcleo del sistema. En la v1.1 es un módulo de carga inicial dentro de un sistema que sigue cargando datos nuevos, y por eso reutiliza la validación común, deja trazabilidad en la base y agrega dos garantías: un modo de ensayo y la continuidad de los legajos.

Este documento es el diseño. El script todavía no está escrito (Fase 3).

2. Qué cambia respecto de la v1.0

Tema	v1.0	v1.1	Motivo
Rol del ETL	Núcleo del sistema	Módulo de carga inicial, de una sola ejecución	Cambio de alcance pedido por la cátedra
Validación	Reglas propias del script	Capa de validación común (RF-VAL-01), la misma del formulario y la carga masiva	Una sola definición de qué es un dato válido
Orden de carga	Carreras, materias, alumnos, inscripciones y actas	Carreras, materias, alumnos y actas	Las inscripciones no tienen fuente legacy
Legajos	No contemplados	Dos pasadas y sincronización del contador (RF-MIG-06)	Que los alumnos nuevos continúen la numeración sin choques

Tema	v1.0	v1.1	Motivo
Modo de ensayo	No existía	Mismo proceso que termina siempre en ROLLBACK (RF-MIG-05)	Probar la migración sin tocar la base
Trazabilidad	Solo el log de errores	Un lote por archivo en `lotes_carga` y `origen = 'MIGRACION'`	RF-MIG-05 y RF-CMA-04
Errores	ERR_01 a ERR_04 con otro alcance	Catálogo del Diccionario v1.2 (ERR_01 a ERR_05, más ERR_09 y WARN_01)	Un solo catálogo
Ejecución	Sin control de quién ni cuántas veces	Solo el Administrador y una sola migración definitiva	RF-MIG-05

3. Flujo general

El proceso tiene cinco etapas, de la 0 a la 4. El diagrama de flujo de datos está en `Diagrama_Flujo_ETL_v1.1.drawio`.

Etapa	Qué hace	Salida	Si falla
0. Pre-chequeos	Verifica que quien ejecuta sea Administrador, que no exista una migración definitiva registrada en `lotes_carga` (tipo MIGRACION), que estén los tres archivos y que tengan las columnas esperadas.	Luz verde	Aborta sin tocar la base
1. Extracción	Lee los .xlsx y el .csv sin asumir tipos: todo entra como texto. Arma el staging en memoria.	Tres tablas de staging	Aborta si no puede abrir un archivo

Etapa	Qué hace	Salida	Si falla
2. Transformación y validación	Aplica fila por fila las reglas del Diccionario (sección 2): normaliza lo que se puede corregir y rechaza lo que no.	Filas válidas y filas rechazadas	Las filas inválidas no detienen el proceso
3. Carga transaccional	Inserta todo dentro de una única transacción (sección 5).	Datos en la base, o nada	Un error crítico deshace todo
4. Cierre e informe	Confirma (COMMIT) o deshace (ROLLBACK, en ensayo), cierra los lotes y escribe el informe.	Informe y archivos de salida	n/a

4. Transformación y validación

Las reglas de normalización y los mapeos de columnas están en el Diccionario (secciones 2 y 4) y no se repiten acá. Lo que decide esta etapa es qué se hace con cada fila:

Código	Caso	Tratamiento en la migración
ERR_01	DNI repetido en el archivo	Se conserva la primera aparición. Las siguientes se omiten y se registran.
ERR_02	DNI o código de materia inexistente en un acta	Se rechaza el acta y se la escribe en `inconsistencias_actas.csv`.
ERR_03	Fecha inválida o futura	En alumnos: se carga con fecha de nacimiento nula y se marca para revisión. En actas: se rechaza, porque `fecha_examen` es obligatoria.
ERR_04	Nota fuera de 1 a 10	Se rechaza el acta.
ERR_05	E-mail inválido	El alumno se carga sin e-mail y se registra.
ERR_09	Código de materia repetido en el plan de estudios	Se conserva la primera aparición; las siguientes se omiten y se registran.
WARN_01	Dos alumnos con el mismo legajo legado y DNI distinto	Se carga el primero con su legajo; el segundo recibe uno nuevo y se registra la advertencia.

Los códigos ERR_06 a ERR_08 del Diccionario (correlatividad, permiso de docente y plantilla incorrecta) no aplican a la migración. Los datos históricos no se validan por correlatividad.

La v1.0 y el Diccionario v1.1 hablaban de una tabla temporal `Inconsistencias_Actas`. Esa tabla no existe en el esquema: se reemplaza por el archivo `inconsistencias_actas.csv`, para no agregar tablas que se usan una sola vez.

5. Carga transaccional

Todo ocurre dentro de una sola transacción, en este orden:

1. **Lotes:** se crea una fila de `lotes_carga` por archivo (`alumnos`, `plan_estudios` y `actas_examen`), con el usuario Administrador.
2. **Carreras y materias:** primero las carreras distintas del plan y luego las materias, con su carrera.
3. **Alumnos con legajo legado:** se insertan con su legajo original y `origen = 'MIGRACION'`.
4. **Sincronización del contador:** `CALL sp_sincronizar_legajo()` deja el contador en el mayor legajo cargado.
5. **Alumnos sin legajo:** a cada uno se le pide un número con `sp_proximo_legajo` y se lo inserta ya con ese legajo, sin actualizarlo después.
6. **Actas:** se resuelven el alumno (por DNI) y la materia (por código) contra lo ya cargado, y se insertan con `origen = 'MIGRACION'`, `id_mesa` nulo y el lote correspondiente.
7. **Cierre de lotes:** se completan `filas_total`, `filas_ok` y `filas_error`, de modo que `filas_ok + filas_error = filas_total`.

Los inserts se hacen en tandas (por ejemplo, de 1.000 filas) para cumplir RNF-02.

5.1 Por qué los legajos van en dos pasadas

Si se asignaran legajos nuevos antes de haber cargado todos los legados, un número generado podría coincidir con el de un alumno que todavía no se insertó y la carga fallaría por el UNIQUE. Cargando primero los legajos legados y sincronizando el contador después, los nuevos siempre quedan por encima del mayor existente (RF-MIG-06).

5.2 Control de transacciones (pseudocódigo)

```
def migrar(modo, admin):            # modo: "ensayo" (por defecto) o
"definitivo"
    prechequeos(admin)              # etapa 0: aborta sin tocar la base si
algo falla
```

```
    staging = extraer(archivos)     # etapa 1
    validas, rechazadas = transformar(staging)   # etapa 2, validación común
    try:
        db.execute("SET @app_user_id = %s", [admin.id_usuario])
        db.execute("START TRANSACTION")
        lotes = crear_lotes(tipo="MIGRACION")           # uno por archivo
        cargar_carreras_y_materias(validas)
        cargar_alumnos_con_legajo(validas)
        db.execute("CALL sp_sincronizar_legajo()")
        cargar_alumnos_sin_legajo(validas)              # usa
sp_proximo_legajo
        cargar_actas(validas)                           # con lookup de DNI y
materia
        cerrar_lotes(lotes, validas, rechazadas)
        db.execute("ROLLBACK" if modo == "ensayo" else "COMMIT")
    except DatabaseError as err:
        db.execute("ROLLBACK")
        registrar_falla_critica(err)
    finally:
        db.execute("SET @app_user_id = NULL")
        escribir_informe(modo, validas, rechazadas)
```

6. Modo de ensayo

El ensayo ejecuta las etapas 0 a 3 exactamente igual que la migración definitiva y, al final, hace ROLLBACK. Sirve para ver cuántas filas se cargarían, cuántas se rechazarían y por qué, sin dejar nada en la base. Por seguridad es el modo por defecto: la migración definitiva hay que pedirla de forma explícita.

Qué se deshace y qué no:

- **Se deshace todo lo que escribe la carga:** alumnos, materias, actas, lotes, los eventos de auditoría que disparan los triggers y el contador de legajos, que vive en `parametros` y es transaccional.
- **No se deshacen los contadores AUTO_INCREMENT** de los ids internos (`id_alumno`, `id_acta`, etc.). Tras un ensayo, la migración real arranca con ids más altos y con huecos. Son claves internas que el usuario no ve, así que no afecta; los legajos sí salen sin huecos. Si se prefieren ids contiguos, se ensaya sobre una copia de la base.

La migración definitiva corre una sola vez. Los pre-chequeos se niegan a ejecutarla, en cualquier modo, si ya hay un lote de tipo MIGRACION en `lotes_carga`.

7. Archivos de salida

Archivo	Contenido
`errores_migracion.log`	Una línea por fila rechazada, omitida o advertida: archivo, número de fila, campo, valor original, código y acción.
`inconsistencias_actas.csv`	Las actas rechazadas por ERR_02, completas, para revisión manual.
`informe_migracion.txt`	Por cada archivo: filas leídas, cargadas y rechazadas, con el detalle por código de error; legajos asignados y contador final; modo y fecha. Se genera siempre, también en ensayo y ante una falla crítica.

8. Criterios de aceptación con los datos de prueba

Con los archivos simulados y su `Clave_Errores_Inyectados.xlsx`, el ensayo debe informar exactamente esto (Fase 4):

Archivo	Leídas	Rechazadas u omitidas	Cargadas	Detalle
Alumnos_2026_Final.xlsx	83	3	80	ERR_01 en las filas 43, 53 y 68. Entre las cargadas: 4 con ERR_05 (sin e-mail) y 2 con ERR_03 (fecha de nacimiento nula).
Plan_Estudios.xlsx	25	1	24 (2 carreras)	ERR_09 por el código repetido.
Actas_Historicas.csv	204	15	189	ERR_02: 8 (4 por DNI y 4 por materia). ERR_03: 4 (2 inválidas y 2 futuras). ERR_04: 3.

Legajos con estos datos: 76 alumnos conservan el legado y 4 no lo tienen. El mayor legajo cargado es 1082, así que el contador se sincroniza en 1082, los 4 alumnos sin legajo reciben del 1083 al 1086 y el próximo alumno nuevo recibirá el 1087.

Si el ensayo informa otros números, hay un error en el ETL o en la clave.

9. Decisiones y riesgos abiertos

Nº	Tema	Propuesta	Por qué importa
1	Auditoría durante la migración	Dejar los triggers activos y medir. Si no se cumple RNF-02, agregar una bandera que pause la auditoría solo durante la migración.	Cada acta insertada dispara un trigger que escribe un evento en `auditoria`: duplica los inserts. No se midió.
2	Ensayo en la misma base o en una copia	Misma base, aceptando huecos en los ids internos.	Es más simple y no afecta a los legajos.
3	Qué duplicado se conserva	La primera aparición en el archivo, como dice el Diccionario.	No hay un criterio universal. Con datos reales conviene revisar los DNI duplicados antes de migrar.
4	Implementación	Escribir el script en la Fase 3 y verificarlo contra la sección 8.	Este documento es solo el diseño: nada de esto se ejecutó todavía.